TENDÊNCIAS EM INTELIGÊNCIA COMPUTACIONAL

ESTIMATIVA DOS PARÂMETROS TRI

Professor: Rodrigo Gabriel Ferreira Soares

Alunos
Fábio Jorge Coelho De Farias Filho
João Henrique dos Santos Silva

CONTEXTO

A **Teoria de Resposta ao Item (TRI)** é amplamente utilizada em plataformas educacionais para estimar a proficiência (θ) dos alunos com base em seu desempenho em questões calibradas.
Cada questão precisa de três parâmetros conhecidos:

- **a** — discriminação;
- **b** — dificuldade;
- **c** — acerto ao acaso;

Questões de plataformas externas, como SAS e Poliedro, geralmente não possuem parâmetros de dificuldade calibrados ou disponibilizados publicamente. Isso dificulta sua utilização em modelos de estimativa de proficiência e impede que estudantes identifiquem com precisão questões fáceis, médias ou difíceis. A ausência dessa classificação pode resultar em um uso ineficiente do tempo durante a prova. Nossa proposta busca caracterizar automaticamente novas questões quanto ao seu nível de dificuldade, permitindo uma melhor priorização durante a resolução. Assim, o estudante poderá focar inicialmente em questões mais fáceis e deixar as mais difíceis para o final. Tradicionalmente, esses parâmetros são obtidos por meio de pré-aplicações em grupos menores de participantes.

O PROBLEMA

Simulados externos (SAS, Poliedro) são amplamente utilizados, mas geralmente não fornecem os parâmetros psicométricos a, b e c das questões, essenciais para a TRI.

Sem os parâmetros a, b e c, não é possível incorporar essas questões ao modelo TRI da plataforma para estimar a proficiência θ dos alunos com precisão.

Como mensurar a nota de simulados com questões externas de forma válida?
É necessário um método para estimar a, b e c a partir de informações observáveis de questões anteriores.

PERGUNTA DE PESQUISA



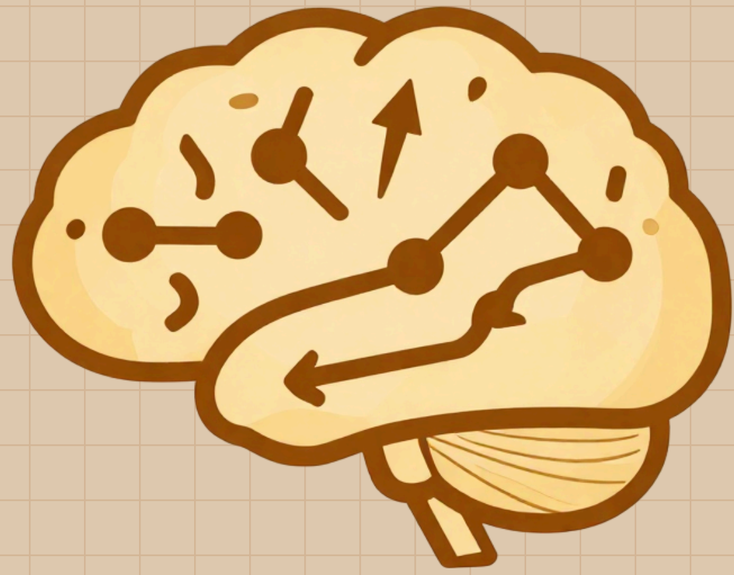
É possível estimar os parâmetros a, b e c de uma questão a partir de suas características observáveis?

Se bem-sucedido, o modelo permite incorporar questões externas (SAS/Poliedro) à plataforma sem necessidade de aplicação prévia em larga escala.

Características observáveis incluem: texto, estrutura, nível declarado, área do conhecimento, número de alternativas e estatísticas de desempenho quando disponíveis.
A hipótese é que existe uma relação estatisticamente aprendível entre essas features e os parâmetros TRI (a, b, c), que um modelo de Aprendizado de Máquina supervisionado pode capturar.
A validação ocorre comparando os parâmetros estimados com os parâmetros calibrados a partir de respostas reais.

POR QUE APRENDIZADO DE MÁQUINA?

A calibração pela TRI é um processo iterativo e custoso, que exige dados de resposta em larga escala. Questões externas, como SAS e Poliedro, chegam sem os parâmetros aa, bb e cc, dificultando sua incorporação aos modelos de proficiência. A proposta é reformular a calibração como um problema de regressão supervisionada, no qual modelos de Machine Learning, especialmente técnicas de Processamento de Linguagem Natural baseadas em Transformers, analisam características textuais e estruturais das questões. A partir de um vetor de características observáveis, o modelo aprende a estimar os parâmetros TRI correspondentes, permitindo caracterizar automaticamente novas questões. Essa abordagem proporciona maior escalabilidade, reprodutibilidade e integração, além de possibilitar uma estimativa mais eficiente da dificuldade das questões e auxiliar o estudante na priorização durante a prova.



FORMULAÇÃO DO PROBLEMA

Entrada (X): características observáveis de cada questão, extraídas do enunciado, das alternativas e de sua estrutura, utilizando técnicas de Processamento de Linguagem Natural.

Modelo de ML: modelo de regressão supervisionada que aprende o mapeamento X → (a, b, c) a partir de um conjunto de questões previamente calibradas pela TRI.

Saída estimada ($\hat{y}$): tripla de parâmetros ($\hat{a}$, $\hat{b}$, $\hat{c}$), em que $\hat{a}$ representa a discriminação, $\hat{b}$ representa a dificuldade e $\hat{c}$ representa a probabilidade de acerto ao acaso.

Objetivo: minimizar o erro entre os parâmetros estimados pelo modelo e os parâmetros de referência obtidos por meio da calibração TRI clássica.

Aplicação: utilizar o modelo para estimar os parâmetros de novas questões externas, como SAS e Poliedro, sem a necessidade de uma nova calibração em larga escala para cada questão.

FEATURES DAS QUESTÕES

As características extraídas de cada questão são organizadas em quatro categorias:

Textuais: comprimento do enunciado, complexidade lexical, número de alternativas e presença de negação.

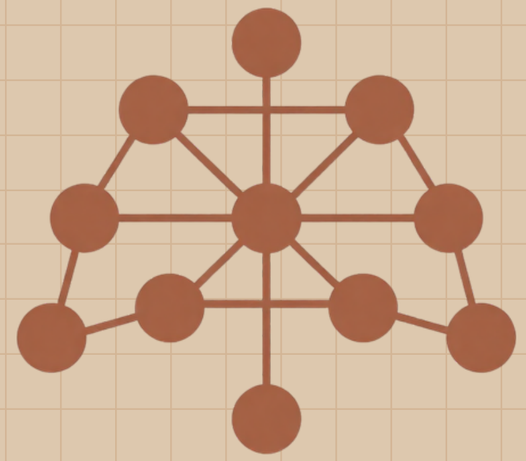
Estruturais: tipo de comando, formato das alternativas e presença de imagens ou fórmulas.
Pedagógicas: área de conhecimento, disciplina e competências avaliadas.

Estatísticas: padrões de desempenho e informações de resposta obtidas a partir de questões previamente calibradas.

PIPELINE EXPERIMENTAL

- Coleta de Dados
- Pré-processamento
- Treino / Validação / Teste
- Regressão & Avaliação

MODELOS DE ML



Baseline & Lineares
Regressão Linear Múltipla como baseline. Modelo simples, interpretável e de referência para comparação. Aplicado de forma multi-output (â, b̂, ĉ simultâneos) e modelos independentes por parâmetro.

Ensemble & Boosting
Random Forest e Gradient Boosting (XGBoost): capturam não-linearidades e interações entre features. Robustos a outliers. Comparados em configuração multi-output vs. regressões independentes para a, b e c.

Redes Neurais (MLP)
Multilayer Perceptron com camadas densas: aprende representações complexas das features. Avaliado em saída conjunta (multi-output) e separada. Comparação final por MAE, RMSE e R^2 em cada parâmetro TRI.

MÉTRICAS DE AVALIAÇÃO

MAE (Erro Absoluto Médio): mede o desvio médio entre os parâmetros estimados e os valores de referência obtidos pela TRI. É calculado individualmente para â, b̂ e ĉ, permitindo avaliar o erro de cada parâmetro de forma direta e interpretável.

RMSE (Raiz do Erro Quadrático Médio): penaliza erros maiores de forma mais intensa, sendo mais sensível a valores discrepantes (outliers). É utilizado para identificar estimativas significativamente distantes dos parâmetros de referência obtidos pela TRI.

R^2 (Coeficiente de Determinação): indica a proporção da variância dos parâmetros de referência explicada pelo modelo. Valores próximos de 1 indicam maior capacidade do modelo de explicar e estimar os parâmetros da TRI.



LIMITAÇÕES E VALIDADE

Qualidade do Ground Truth: os parâmetros a, b e c utilizados como referência dependem de uma calibração TRI prévia, que pode apresentar erros de estimação e vieses decorrentes da amostra de respondentes utilizada.

Tamanho e Diversidade do Dataset: a quantidade e a diversidade de questões com parâmetros calibrados podem ser insuficientes para garantir uma generalização robusta, limitando a capacidade preditiva dos modelos de ML.

Generalização entre Bancas: modelos treinados com questões de SAS e Poliedro podem apresentar desempenho reduzido ao serem aplicados a outras bancas, devido a diferenças no estilo e na elaboração das questões. Além disso, as estimativas podem divergir dos parâmetros oficiais em razão de diferenças metodológicas.



CONCLUSÃO

O projeto propõe um pipeline automatizado para estimar os parâmetros a, b e c da TRI em questões que não possuem calibração prévia:

Características da questão → ML → (â, $\hat{b}$, ĉ) → TRI → Proficiência estimada

A abordagem busca reduzir a dependência de calibrações em larga escala, tornando o processo mais escalável, reprodutível e automatizado. Com isso, novas questões de plataformas externas podem ser incorporadas aos modelos de proficiência e utilizadas de forma mais estratégica pelos estudantes.

A qualidade das estimativas dependerá da qualidade, quantidade e diversidade das questões calibradas, além da capacidade de generalização do modelo entre diferentes bancas.